



Tema 3: Descenso de la pendiente

- Descenso de la pendiente.
- Función coste o de perdidas.
- Aplicación del descenso de la pendiente a un perceptrón sigmoide.
- Algoritmo de actualización de pesos en un perceptrón sigmoide.


Descenso de la pendiente:



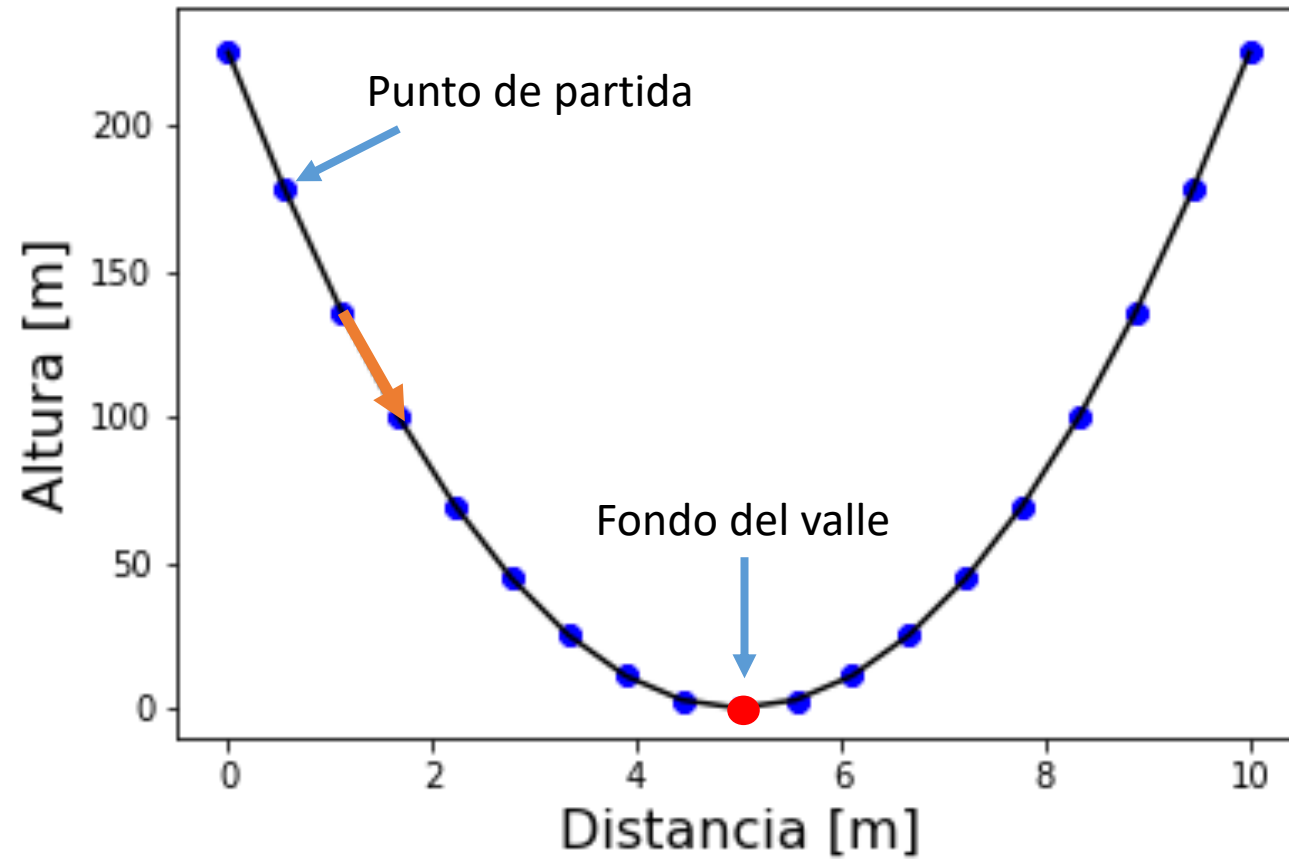
Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:



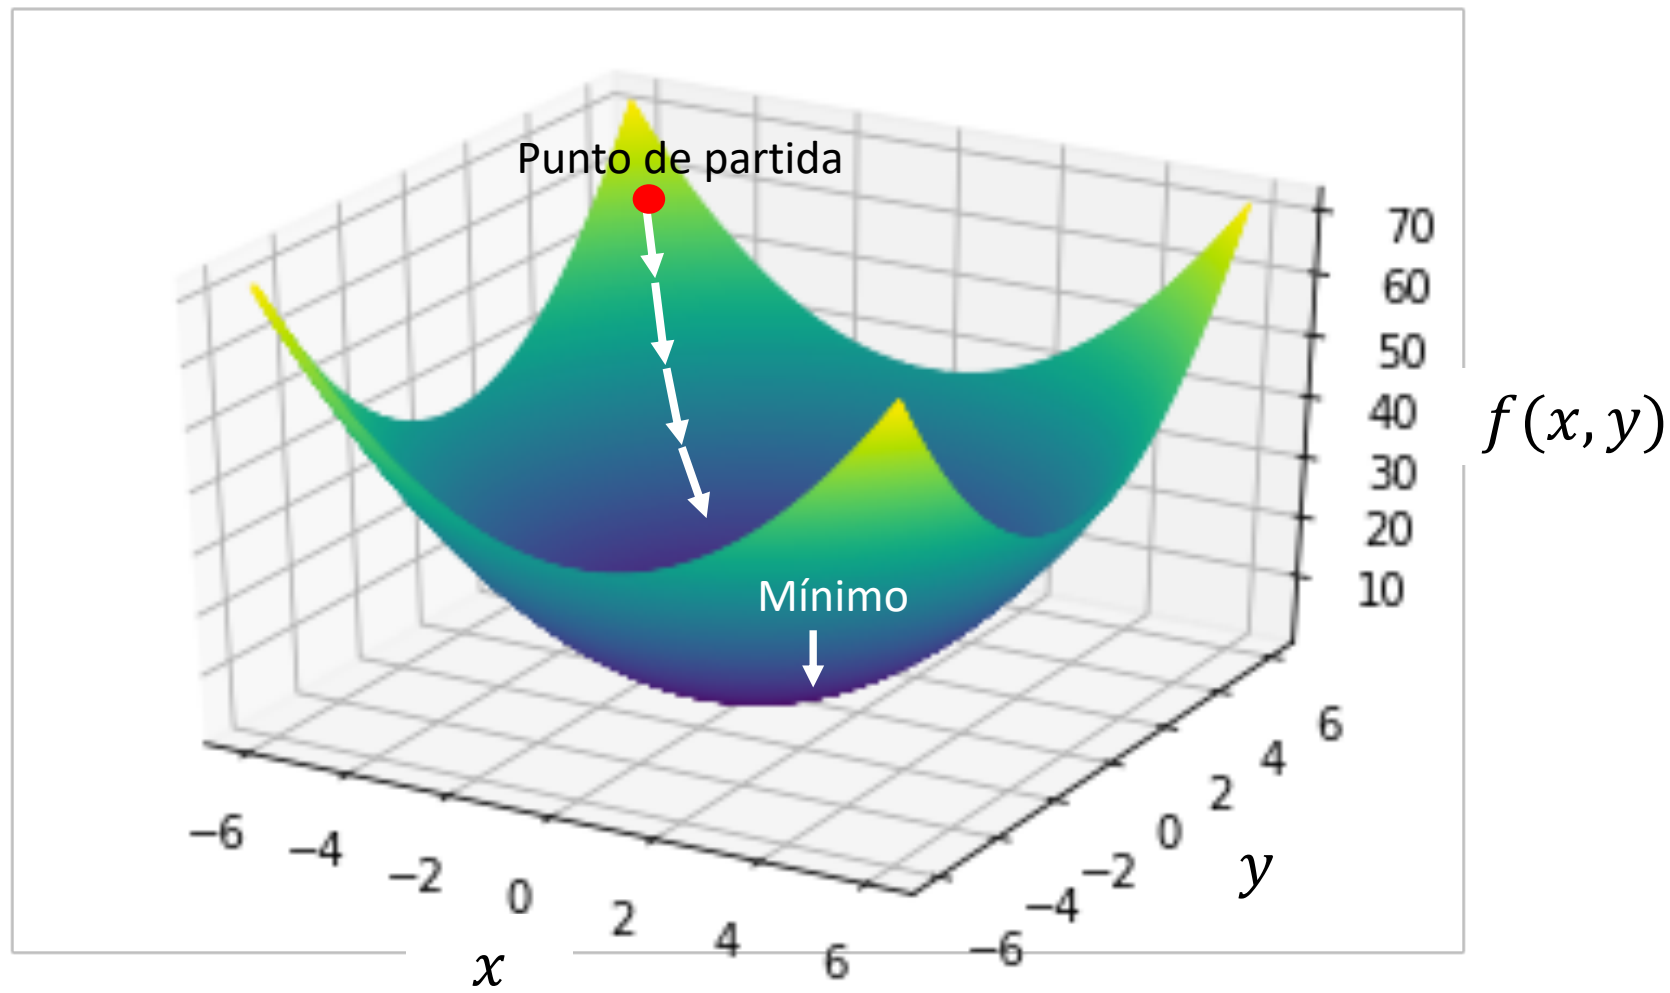
Descenso de la pendiente:




Descenso de la pendiente:




Descenso de la pendiente:



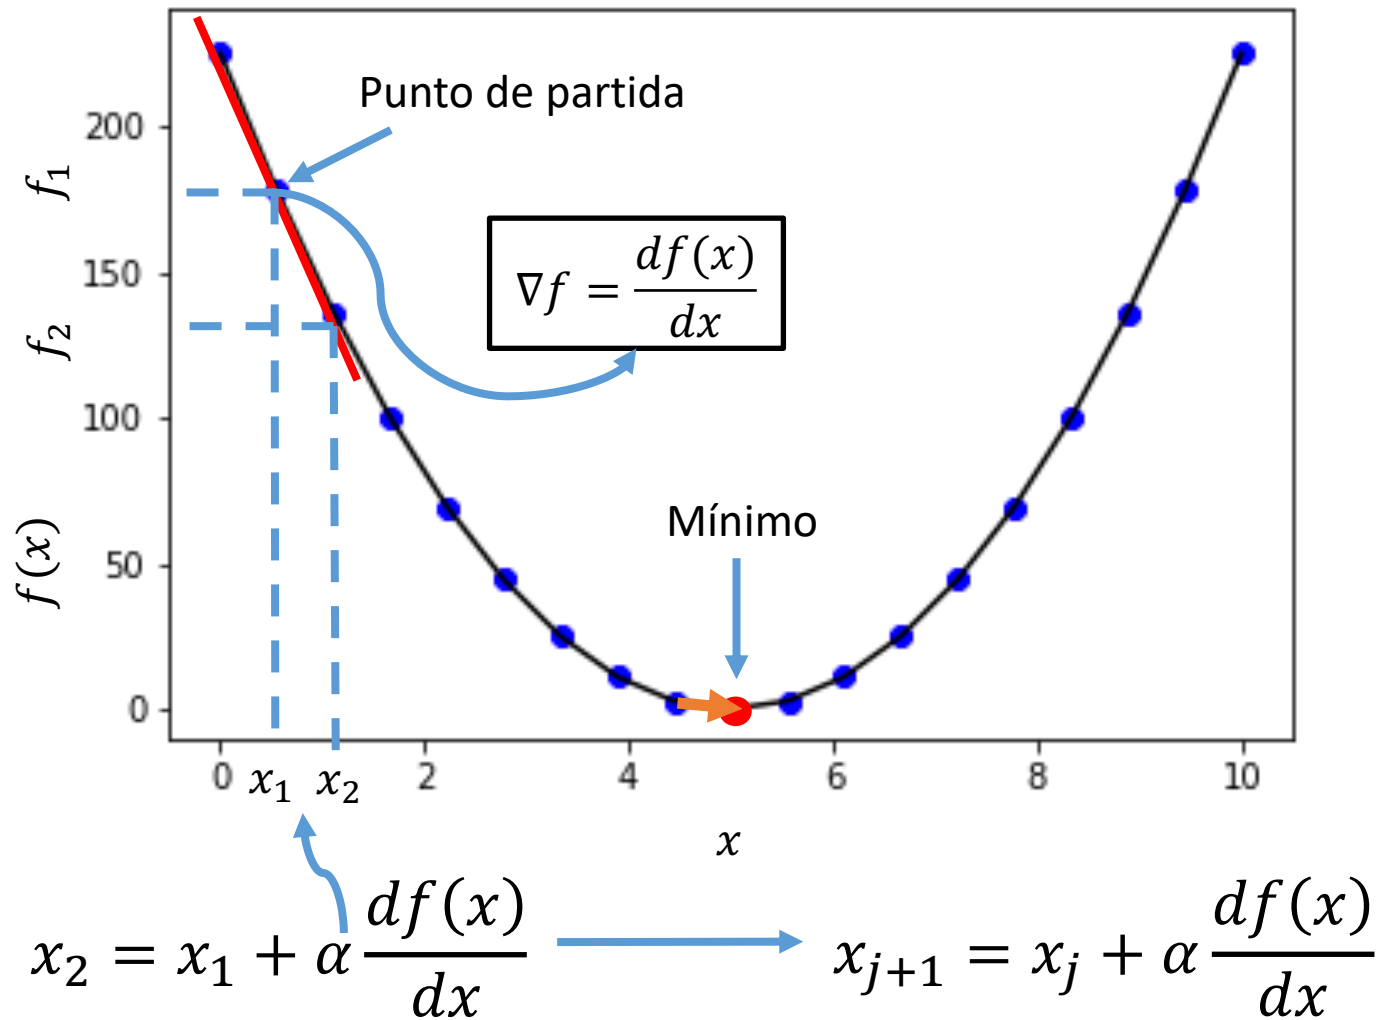
Descenso de la pendiente:




Descenso de la pendiente:



Descenso de la pendiente:




Descenso de la pendiente:



$f(x, y)$

$$\nabla f(x, y) = \begin{bmatrix} \frac{\partial f(x, y)}{\partial x} \\ \frac{\partial f(x, y)}{\partial y} \end{bmatrix}$$

Descenso de la pendiente:




$$\nabla f(x, y) = \begin{bmatrix} \frac{\partial f(x, y)}{\partial x} \\ \frac{\partial f(x, y)}{\partial y} \end{bmatrix}$$

$f(x, y)$


$$\begin{cases} f(x_{j+1}, y_{j+1}) \\ x_{j+1} = x_j + \alpha \frac{\partial f(x, y)}{\partial x} \\ y_{j+1} = y_j + \alpha \frac{\partial f(x, y)}{\partial y} \end{cases}$$

Descenso de la pendiente:




- α pequeños: tiempos de convergencia lentos.

Descenso de la pendiente:




- α grandes: puede no converger.

Descenso de la pendiente:




- α grandes: puede no converger.

Descenso de la pendiente:




- α grandes: puede no converger.

Descenso de la pendiente:




- α grandes: puede no converger.

Descenso de la pendiente:



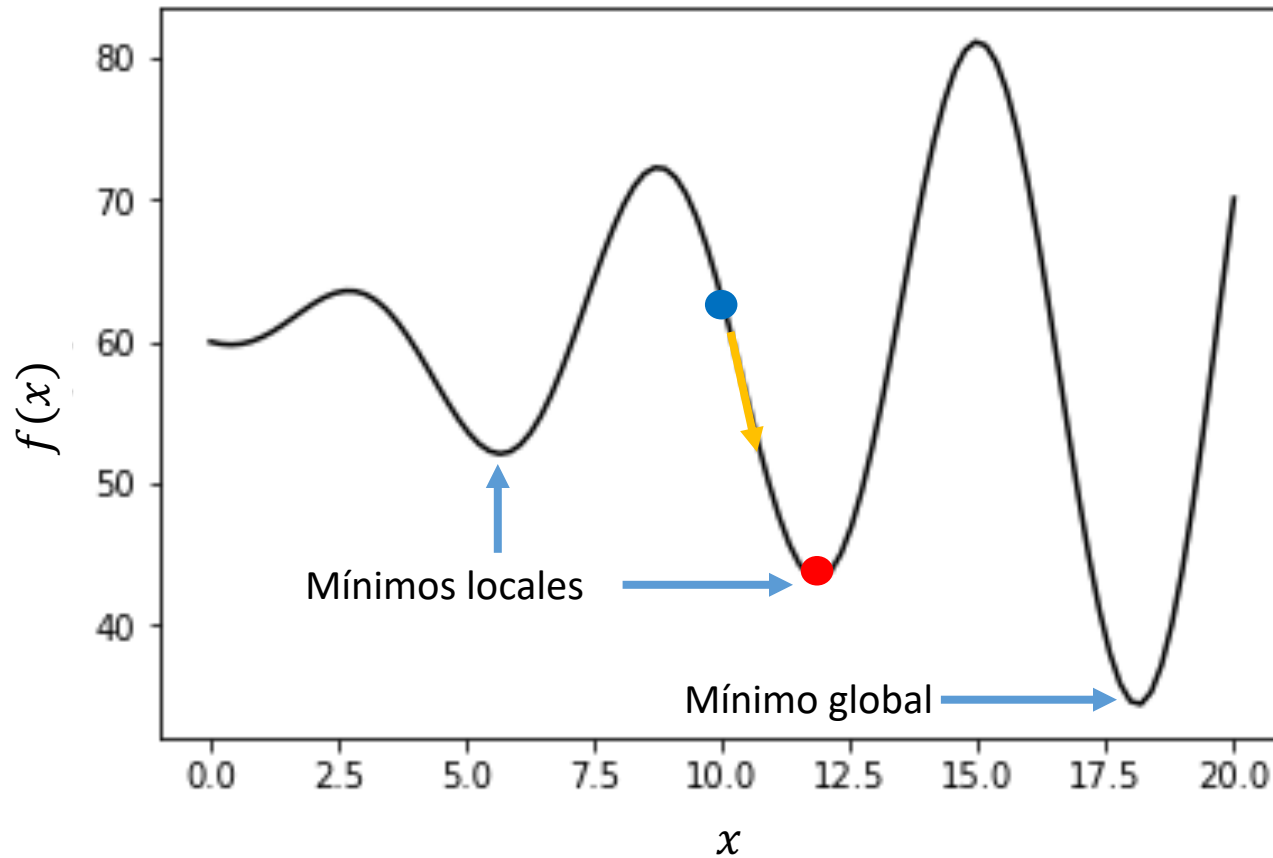
- α grandes: puede no converger.

Descenso de la pendiente:



- α grandes: puede no converger.

Descenso de la pendiente:



- Funciones no convexas: podemos caer en mínimos locales.

Descenso de la pendiente:

- Gradiente, f :

- Una variable: $\nabla f(x) = \frac{df(x)}{dx}$.

- Varias variables: $\mathbf{x} = [x_1, x_2, \dots, x_n] \Rightarrow \nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f(\mathbf{x})}{\partial x_1} \\ \dots \\ \frac{\partial f(\mathbf{x})}{\partial x_2} \end{bmatrix}$.

Descenso de la pendiente:

- Gradiente, f :

- Una variable: $\nabla f(x) = \frac{df(x)}{dx}$.

- Varias variables: $\mathbf{x} = [x_1, x_2, \dots, x_n] \Rightarrow \nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f(\mathbf{r})}{\partial x_1} \\ \dots \\ \frac{\partial f(\mathbf{r})}{\partial x_n} \end{bmatrix}$.

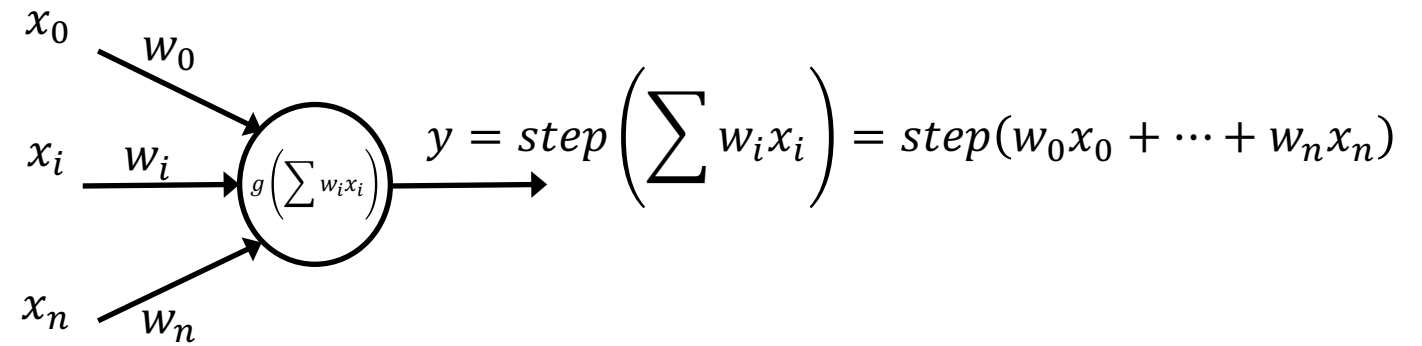
- En el caso de una neurona artificial, f función perdidas:

- $\mathbf{w} = [w_1, w_2, \dots, w_n] \Rightarrow \nabla f(\mathbf{w}) = \begin{bmatrix} \frac{\partial f(\mathbf{w})}{\partial w_1} \\ \dots \\ \frac{\partial f(\mathbf{w})}{\partial w_2} \end{bmatrix}$.

Perceptrón:

- Perceptron:

- Devuelve 1 Devuelve 0 si la suma ponderada de las entradas es menor o igual que un umbral.




- Problemas del perceptron:

- y no es diferenciable.
- y es una función discontinua de las entradas
- Siempre da una predicción segura que es '0' o '1'.

Perceptrón sigmoide:

- Vamos a utilizar la función sigmoide que es continua y diferenciable:



Perceptrón sigmoide:

- ¿Como actualizamos los coeficientes del perceptrón sigmoide?
 1. Definimos una función de pérdidas: $f = Loss(w_1, \dots, w_2) = (y_d - y)^2$

Perceptrón sigmoide:

- ¿Como actualizamos los coeficientes del perceptrón sigmoide?
 1. Definimos una función de pérdidas: $f = Loss(w_1, \dots, w_2) = (y_d - y)^2$
 2. Utilizando el descenso de la pendiente:
 - $w_i \leftarrow w_i + \beta \frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2)$

Perceptrón sigmoide:

- ¿Como actualizamos los coeficientes del perceptrón sigmoide?

1. Definimos una función de pérdidas: $f = Loss(w_1, \dots, w_2) = (y_d - y)^2$

2. Utilizando el descenso de la pendiente:

- $w_i \leftarrow w_i + \beta \frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2)$

- $\frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2) = \frac{\partial}{\partial w_i} (y_d - y)^2 = 2(y_d - y) \frac{\partial}{\partial w_i} (y_d - y) = -2(y_d - y) \frac{\partial y}{\partial w_i}.$

Perceptrón sigmoide:

- ¿Como actualizamos los coeficientes del perceptrón sigmoide?

1. Definimos una función de pérdidas: $f = Loss(w_1, \dots, w_2) = (y_d - y)^2$

2. Utilizando el descenso de la pendiente:

- $w_i \leftarrow w_i + \beta \frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2)$

- $\frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2) = \frac{\partial}{\partial w_i} (y_d - y)^2 = 2(y_d - y) \frac{\partial}{\partial w_i} (y_d - y) = -2(y_d - y) \frac{\partial y}{\partial w_i}.$

- $y = \frac{1}{1+e^{-\sum w_i x_i}} \Rightarrow \frac{\partial y}{\partial w_i} = y(1 - y) x_i.$

Perceptrón sigmoide:

- ¿Como actualizamos los coeficientes del perceptrón sigmoide?

1. Definimos una función de pérdidas: $f = Loss(w_1, \dots, w_2) = (y_d - y)^2$

2. Utilizando el descenso de la pendiente:

- $w_i \leftarrow w_i + \beta \frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2)$

- $\frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2) = \frac{\partial}{\partial w_i} (y_d - y)^2 = 2(y_d - y) \frac{\partial}{\partial w_i} (y_d - y) = -2(y_d - y) \frac{\partial y}{\partial w_i}.$

- $y = \frac{1}{1+e^{-\sum w_i x_i}} \Rightarrow \frac{\partial y}{\partial w_i} = y(1 - y) x_i.$

- $\frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2) = -2(y_d - y)y(1 - y)x_i.$

Perceptrón sigmoide:

- ¿Como actualizamos los coeficientes del perceptrón sigmoide?

1. Definimos una función de pérdidas: $f = Loss(w_1, \dots, w_2) = (y_d - y)^2$

2. Utilizando el descenso de la pendiente:


- $w_i \leftarrow w_i + \beta \frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2)$

- $\frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2) = \frac{\partial}{\partial w_i} (y_d - y)^2 = 2(y_d - y) \frac{\partial}{\partial w_i} (y_d - y) = -2(y_d - y) \frac{\partial y}{\partial w_i}.$

- $y = \frac{1}{1+e^{-\sum w_i x_i}} \Rightarrow \frac{\partial y}{\partial w_i} = y(1 - y) x_i.$

- $\frac{\partial}{\partial w_i} Loss(w_1, \dots, w_2) = -2(y_d - y)y(1 - y)x_i.$

- $w_i \leftarrow w_i + \alpha (y_d - y)y(1 - y)x_i.$



Perceptrón sigmoide:

- Entrenamiento:
 1. Se asignan pesos aleatorios a las entradas:
 - $w_i \in (-0.5, 0.5)$.

Perceptrón sigmoide:

- Entrenamiento:
 1. Se asignan pesos aleatorios a las entradas:
 - $w_i \in (-0.5, 0.5)$.
 2. Se presenta el siguiente conjunto de datos de entrenamiento en las entradas y se observa la salida.

Perceptrón sigmoide:

- Entrenamiento:

1. Se asignan pesos aleatorios a las entradas:

- $w_i \in (-0.5, 0.5)$.

2. Se presenta el siguiente conjunto de datos de entrenamiento en las entradas y se observa la salida.

3. Si la salida es incorrecta se cambian los valores de los pesos de acuerdo con la expresión:

- $w_i \leftarrow w_i + \alpha (y_d - y)y(1 - y)x_i$.

Perceptrón sigmoide:

- Entrenamiento:

1. Se asignan pesos aleatorios a las entradas:

- $w_i \in (-0.5, 0.5)$.

2. Se presenta el siguiente conjunto de datos de entrenamiento en las entradas y se observa la salida.

3. Si la salida es incorrecta se cambian los valores de los pesos de acuerdo con la expresión:

- $w_i \leftarrow w_i + \alpha (y_d - y)y(1 - y)x_i$.

- Se repite el procedimiento hasta que el error esté por debajo del deseado.